

PPO 기반 따릉이 재배치 실험 보고서

Clipped policy update 와 Top-K 후보 행동 구조가 PPO 안정성에 미친 영향

작성자: 박제영(A73024)

Abstract

본 문서는 서울 25 개 구 따릉이 재배치 환경에서 수행한 MaskablePPO 실험을 정리한다. 평가는 2025-10-20 부터 2025-12-31 까지 73 일 chronological holdout 으로 수행했고, MostImbalanced baseline 대비 Delta 를 주 지표로 사용했다. Top-K12 전체 실험에서 PPO 는 Best Delta 평균 +2.7, baseline 초과 14/25 구였지만, Final Delta 평균은 -23.5 로 떨어졌다. Top-K3 seed 반복 실험에서는 Best/Worst subset 의 모든 Best 결과가 baseline 을 초과했고, PPO diagnostics 에서는 clip_fraction 이 대부분 0 근처였다.

1. 문제 정의와 PPO 적용 이유

따릉이 재배치는 재배치 트럭이 여러 정류소를 순차적으로 방문하며 stockout, full, 이동 비용을 줄이는 문제다. PPO 를 적용한 이유는 clipped surrogate objective 와 target_kl 을 통해 policy update 가 과도하게 커지는 것을 제한할 수 있기 때문이다.

본 실험에서는 sb3-contrib MaskablePPO 를 사용했다. Top-K 후보 행동 구조와 action mask 를 함께 사용해, PPO 가 전체 정류소가 아니라 후보 rank 중 하나를 선택하도록 했다.

2. State, Action, Reward

항목	설계
State	현재 재고, capacity, 트럭 상태, 시간 정보, 1 시간 수요예측 feature
Action	전체 정류소가 아니라 Top-K 후보 rank 선택
Reward	stockout, full, 이동거리, 이동 step 비용의 음수 합
Metric	Delta = PPO reward - MostImbalanced reward

```
candidate_score = forecast_imbalance - travel_coef * travel_distance - zone_penalty
r_t = w_stockout*stockout_t + w_full*full_t + w_travel_km*travel_km_t + w_travel_step*travel_step_t
```

3. PPO 알고리즘

항목	값	이유
구현	sb3-contrib MaskablePPO	rollout/update 단계에서 action mask 사용
Policy net	obs_dim -> 256 -> 256 -> n_actions	Top-K 후보 rank 별 action logit 출력
Value net	obs_dim -> 256 -> 256 -> 1	GAE 와 value loss 계산
gamma / gae_lambda	0.99 / 0.95	장기 보상과 advantage variance 절충
clip_range	0.1	old/new policy ratio 의 과도한 변화 제한
learning_rate	1e-4	보수적 update
n_steps / batch / epochs	256 / 128 / 5	계산 시간과 안정성 절충
target_kl	0.03	KL 이 커질 때 update 조기 제한
ent_coef	0.003	정책 collapse 완화

```
model = MaskablePPO(
    'MlpPolicy', train_env,
    learning_rate=1e-4, n_steps=256, batch_size=128, n_epochs=5,
    gamma=0.99, gae_lambda=0.95, clip_range=0.1,
    ent_coef=0.003, target_kl=0.03,
    policy_kwargs={'net_arch': dict(pi=[256, 256], vf=[256, 256])}),
)

ratio = exp(new_log_prob - old_log_prob)
policy_loss_1 = advantage * ratio
policy_loss_2 = advantage * clamp(ratio, 1-eps, 1+eps)
policy_loss = -mean(min(policy_loss_1, policy_loss_2))
```

```

value_loss = MSE(V(s), return_target)
loss = policy_loss + vf_coef * value_loss - ent_coef * entropy

```

ratio 가 $1 \pm \text{clip_range}$ 밖으로 나가면 policy loss 가 더 커지는 방향으로 무한히 업데이트되지 않는다. 따라서 PPO 는 REINFORCE 보다 update 폭을 직접 제한할 수 있지만, clipping 자체가 성능을 자동으로 올리는 것은 아니다.

4. 실험 설계

실험	대상	목적
Top-K12 full	서울 25 개 구, seed 42	기본 성능과 Best/Final gap 확인
Top-K ablation	Best/Worst subset, K=3/6/9/12/15	PPO 에 적합한 후보 수 탐색
Seed validation	Top-K3, seed 42/123/777	결과 재현성과 분산 확인
Diagnostics	approx_kl, clip_fraction, entropy, explained_variance	PPO 고유 특성 확인

5. Top-K12 전체 결과

실험	구	Best Δ 평균	Best Δ 중앙값	Best 승리	Final Δ 평균	Final Δ 중앙값	Final 승리	Gap 평균
PPO Full TopK12	25	+2.7	+4.7	14	-23.5	-5.5	8	+26.2




Figure 1. PPO Top-K12 25 개 구별 Best/Final Delta




Figure 2. PPO Top-K12 전체 학습곡선

Top-K12에서는 Best 기준으로 절반 이상의 구에서 baseline 을 넘었지만, Final 기준에서는 하락한 구가 많았다. 따라서 PPO 평가는 Best checkpoint와 Final checkpoint를 함께 봐야 한다.

6. Top-K ablation

Top-K	구	Best Δ 평균	Best Δ 중앙값	Best 승리	Final Δ 평균	Final Δ 중앙값	Final 승리	Gap 평균
3	6	+35.1	+41.2	6	+29.6	+31.5	6	+5.5
6	6	+39.8	+48.3	6	+8.8	+15.0	4	+31.0
9	6	-2.5	+7.0	4	-19.0	+5.8	4	+16.5
12	6	-5.2	+5.9	3	-58.6	-48.4	2	+53.4
15	6	-4.7	-7.5	3	-18.7	-7.5	3	+14.1

PPO Top-K ablation: 후보 수가 작을수록 안정성이 좋아진 subset




Figure 3. PPO Top-K 후보 수 ablation

Best/Worst subset에서는 Top-K3가 가장 안정적이었다. 후보 수를 줄이면 PPO가 학습해야 할 action rank가 줄어들어 Final 성능 유지에 유리했다.

7. Seed validation

구 수	실험 수	Best Δ 평균	Best std 평균	Best std 중앙값	Final Δ 평균	Final std 평균	Final std 중앙값
-----	------	------------------	-------------	--------------	-------------------	--------------	---------------

6	18	+34.9	10.3	10.6	+26.8	17.4	15.5
---	----	-------	------	------	-------	------	------

구	Best Δ 평균	Best std	Final Δ 평균	Final std
노원구	+39.1	12.4	+38.3	13.5
동대문구	+4.6	2.5	+4.2	2.2
마포구	+45.1	0.7	+45.0	0.7
송파구	+37.6	21.7	+27.3	39.5
양천구	+35.6	15.8	+17.0	31.2
영등포구	+47.4	8.8	+29.1	17.5




Figure 4. PPO Top-K3 seed 반복 실험

8. PPO diagnostics

지표	평균	중앙값	75%	최대
approx_kl	0.0	0	0.0	0.0
clip_fraction	0.0	0	0	0.1
entropy_loss	-0.8	-0.8	-0.7	-0.2
explained_variance	0.4	0.4	0.7	1.0
policy_gradient_loss	-0.0	-0.0	0	0.0
value_loss	5211.5	1083.4	4459.8	59609.5

PPO 내부 진단: clipping은 guard였고 실제 update는 보수적이었다




Figure 5. PPO 내부 진단 시계열

PPO 진단 지표 분포: clip_fraction은 대부분 0 근처




Figure 6. PPO 내부 진단 분포

approx_kl 과 clip_fraction 이 낮았다는 것은 update 가 보수적으로 진행되었다는 뜻이다. 따라서 본 실험에서 PPO 의 안정성은 clipping 이 자주 개입해서 생긴 효과라기보다, 작은 learning rate, target_kl, Top-K 후보 축소가 함께 만든 결과로 해석하는 것이 타당하다.

8.1 PPO policy smoothness proxy

run 수	평균 평가 변화	중앙값 평가 변화	Gap 평균	평균 KL	최대 KL	평균 clip	최대 clip
18	+9.8	+9.3	+8.1	0.0	0.0	0.0	0.1

PPO policy smoothness proxy: 작은 KL, 낮은 clip 비율, 완만한 평가 변화




Figure 7. PPO policy smoothness proxy

PPO가 smooth하다는 말은 본 보고서에서 세 가지 proxy로 정의했다. 평가 Delta 변화폭, approx_kl, clip_fraction이다. Top-K3 seed 반복에서 평균 평가 Delta는 baseline 위를 유지했고, approx_kl은 target_kl=0.03보다 훨씬 낮았으며, clip_fraction도 대부분 0 근처였다.

9. 결론

PPO는 Top-K12 전체 실험에서 Best 기준으로 가능성을 보였지만 Final 안정성은 부족했다. 반면 Top-K3 subset 실험에서는 Best와 Final 모두 안정적으로 baseline을 넘었다. approx_kl과 clip_fraction이 낮았으므로 policy update는 보수적으로 움직였지만, 성능 개선을 clipping 단독 효과로 해석하면 안 된다. Top-K 후보 축소, 낮은 learning rate, target_kl, GAE/value learning이 함께 PPO의 안정성을 만든 것으로 보는 것이 객관적이다.

References

- Schulman et al. (2017), Proximal Policy Optimization Algorithms: clipped surrogate objective의 원 논문.
- OpenAI Spinning Up PPO: PPO-Clip이 old/new policy 변화 유인을 제한하는 방식 설명.
- Henderson et al. (2017), Deep Reinforcement Learning that Matters: RL 실험의 seed/분산 보고 필요성.