

REINFORCE와 A2C를 이용한 서울 따릉이 재배치 강화학습 최종 보고서

수요예측 기반 상태 보강과 Top-K 후보 행동 구조에서 REINFORCE와 A2C를 비교한 결과

작성일: 2026-06-09

Abstract

본 보고서는 서울 25개 구 따릉이 재배치 문제를 REINFORCE with Value Baseline과 A2C로 학습한 최종 결과를 정리한다. DQN과 PPO는 팀원 별도 실험 범위로 분리했기 때문에, 본문 결과표와 결론에서는 제외한다.

최종 평가는 시간순 split을 적용해 2025-10-20부터 2025-10-26까지 7일 평균 reward로 수행했다. A2C는 Best 기준 18개 구, Final 기준 16개 구에서 MostImbalanced baseline을 넘었고 평균 Best Delta는 +24.9였다. REINFORCE는 Best 기준 10개 구에서 baseline을 넘었지만 평균 Best Delta는 -4.4, 평균 Final Delta는 -38.1로 더 불안정했다.

1. 문제 정의와 최적화 목표

따릉이 재배치 문제는 정류소별 자전거 재고가 시간에 따라 변하는 상황에서, 재배치 트럭이 다음에 방문할 정류소를 반복적으로 선택하는 순차 의사결정 문제다. 좋은 정책은 재고 부족과 포화를 줄이면서도 불필요한 이동을 줄이는 정책이다.

```
maximize episode_reward = minimize(stockout penalty + full penalty + travel cost)
```

2. State, Action, Reward 설계

범주	주요 정보
정류소 재고	현재 자전거 수, capacity, 목표 재고 대비 편차
수요예측	1시간 예측 대여량, 반납량, 순수요, 예측 후 재고 편차
트럭 상태	현재 위치, 적재량, 이동 상태
후보 정보	Top-K 후보별 불균형 점수, 이동거리 penalty, 권역 penalty

Action은 전체 정류소 직접 선택이 아니라 매 step마다 수요예측 기반 Top-K 후보 12개 중 하나를 고르는 방식이다. Reward는 stockout, full, 이동 비용을 음수로 계산하며, $\Delta = \text{model reward} - \text{MostImbalanced reward}$ 로 평가한다.

```
r_t = -1.0 * stockout - 0.8 * full - 0.008 * travel_km - 0.002 * travel_step
```

3. 알고리즘

3.1 REINFORCE with Value Baseline

REINFORCE는 episode가 끝난 뒤 reward-to-go를 계산해 policy를 업데이트하는 Monte Carlo policy gradient 알고리즘이다. Value Network를 baseline으로 사용해 advantage 분산을 줄였다.

```
returns = discounted_reward_to_go(rewards, gamma)
advantages = returns - value_net(states)
policy_loss = -(log_probs * advantages.detach()).mean()
value_loss = mse_loss(value_net(states), returns)
```

3.2 A2C

A2C는 Actor가 action 확률분포를 만들고 Critic이 현재 state의 value를 추정한다. TD target을 사용하므로 REINFORCE보다 더 자주 학습 신호를 받을 수 있다.


```
target = reward + gamma * (1 - done) * value(next_state)
advantage = target - value(state)
actor_loss = -(log_prob(action) * advantage.detach()).mean()
critic_loss = mse_loss(value(state), target)
```

4. 실험 설정

항목	설정
대상 지역	서울 25개 구
학습/평가 분할	시간순 chronological split
평가 날짜	2025-10-20 ~ 2025-10-26
학습 길이	500 episodes
평가 주기	50 episodes
Top-K	12
BC/rollback	사용하지 않음. Best checkpoint만 저장 후 평가


5. 최종 결과

Algorithm	구 수	Best 평균 Reward	Final 평균 Reward	Best Δ 평균	Best Δ 중앙값	Final Δ 평균	Best 승리 구	Final 승리 구
A2C	25	-815.6	-827.4	24.9	18.5	13.1	18	16
REINFORCE	25	-844.9	-878.6	-4.4	-7.0	-38.1	10	7




A2C는 Best 기준 18개 구, Final 기준 16개 구에서 baseline을 넘었다. REINFORCE는 Best 기준 10개 구에서 baseline을 넘었지만 Final 기준으로는 7개 구만 baseline을 넘었다.

25개 구 평가 Delta 학습곡선



구별 성능 차이: 잘 되는 구와 어려운 구



6. Seed 안정성 분석

Algorithm	Seed 평균 Best Δ	Seed 표준편차 평균
A2C	17.7	2.0
REINFORCE	-8.0	53.3

Seed 반복 실험에서 A2C의 Best Delta 표준편차 평균은 약 2.0으로 작았고, REINFORCE는 약 53.3으로 컸다. 따라서 REINFORCE는 일부 구에서 높은 성능 가능성을 보이지만, 최종 모델로는 A2C가 더 안정적이다.

7. 결론

최종 chronological split 실험에서 A2C가 REINFORCE보다 평균 성능과 안정성 모두에서 우수했다. A2C는 25개 구 중 Best 기준 18개 구에서 MostImbalanced baseline을 넘었고, 평균 Best Delta는 +24.9였다. REINFORCE는 일부 구에서 A2C와 비슷하거나 더 좋은 결과를 냈지만 평균적으로는 baseline보다 낮았고 seed 민감도가 컸다.

따라서 본 담당 범위에서는 A2C를 주 모델, REINFORCE를 policy gradient 비교 모델로 제시하는 것이 가장 적절하다.

Appendix. 구별 결과

구	Baseline	A2C Best Δ	A2C Final Δ	A2C Best ep	REINFORCE Best Δ	REINFORCE Final Δ	REINFORCE Best ep	Best 승자
강남구	-689.9	50.6	50.6	50	-5.7	-38.7	100	A2C
강동구	-615.2	37.4	28.1	1	0.7	-38.2	100	A2C
강북구	-24.0	-2.7	-6.4	50	-2.7	-2.7	350	A2C
강서구	-4172.9	53.9	53.9	50	-70.6	-116.6	150	A2C
관악구	-147.8	-38.8	-40.4	400	-40.4	-40.4	100	A2C
광진구	-896.5	14.2	14.2	100	14.2	-297.2	100	A2C
구로구	-1037.6	37.9	-21.9	50	-91.0	-107.1	100	A2C
금천구	-436.0	10.0	10.0	200	-41.8	-41.8	500	A2C
노원구	-720.8	72.0	64.3	50	72.0	72.0	50	A2C
도봉구	-149.1	-7.9	-7.9	50	-47.6	-47.6	150	A2C
동대문구	-541.3	27.3	27.3	50	28.8	27.3	150	REINFORCE
동작구	-225.2	-2.3	-2.9	100	-10.3	-56.1	300	A2C
마포구	-911.8	85.6	85.6	50	85.6	-4.1	400	A2C
서대문구	-204.0	-15.0	-15.2	50	-31.6	-54.9	1	A2C
서초구	-349.7	39.3	39.3	500	39.3	39.3	450	A2C
성동구	-975.1	47.3	24.6	150	-34.1	-59.1	50	A2C
성북구	-205.3	-9.6	-9.6	100	-7.8	-41.7	250	REINFORCE
송파구	-2115.7	62.2	62.2	50	63.5	62.2	1	REINFORCE
양천구	-1789.4	29.0	29.0	50	71.6	35.7	100	REINFORCE
영등포구	-3139.1	76.5	-112.9	1	-27.5	-53.6	1	A2C
용산구	-163.2	17.0	17.0	250	17.0	17.0	200	A2C
은평구	-283.2	-9.8	-9.8	50	-7.0	-90.0	250	REINFORCE
종로구	-516.8	18.5	18.5	100	-31.7	-31.7	200	A2C
중구	-380.1	14.0	14.0	100	-68.9	-100.5	50	A2C
중랑구	-322.7	16.7	16.7	100	16.7	16.7	500	A2C