

수요예측과 후보 행동 구조 기반 서울자 전거 따릉이 재배치 강화학습

서울시 공공자전거 환경에서의 강화학습 성능 향상 방안 연구:
REINFORCE · A2C · Double DQN · PPO의 성능 및 안정성 분석

박제영(A73024), 손예진(A73006), 이형진(A73031)



GitHub 링크: [강화학습 프로젝트](#)

TEAM & ROLES

팀 구성 및 역할분담

손예진 (A73006)

핵심 역할

공공데이터를 통한 따릉이 아이디어 제안

따릉이 데이터 수집 및 전처리
시뮬레이션 환경 구축

DQN 학습 및 하이퍼파라미터 튜닝

Replay Viewer 시각화

주요 산출물

- 전처리 Parquet 파일
- DQN Core Algorithms Source 및 모델
- Replay Viewer 시각화 페이지

박제영 (A73024)

핵심 역할

REINFORCE+A2C+VAE 결합 실험
MAB(Contextual Bandit) 실험
모델 구조 최적화 및 하이퍼파라미터 튜닝으로 효율·성능 극대화

주요 산출물

- Multi-RL Core Algorithms Source
- End-to-End 학습 파이프라인

이형진 (A73031)

핵심 역할

PPO/QRDQN 파이프라인 개발 ·
데이터셋 분할 및 다양한 Seed 성능 실험. 검증 지표 수립 및 연구성과 정리, 최종 PPT 작성

주요 산출물

- 개선된 PPO Algorithm Source
- 최종 보고서

PROBLEM

문제정의: 강화학습을 통한 서울 따릉이 최적 배치 수행



01 문제상황 : 출퇴근/주말/날씨에 따라 정류소별 대여/반납이 달라짐

Stockout(-) : 대여실패(자전거 부족) / Full(-) : 반납실패(자전거 만차) 발생

02 문제특성 : 단순 예측 문제가 아니라 순차 의사결정 문제

트럭이 지금 어디로 가는지가 이후 정류소 재고와 다음 선택에 영향을 줌

03 RL 적합성 : 정답 행동 레이블이 없는 문제

시행착오를 통해 스스로 최적 정책을 탐색하는 강화학습 방식 선택

KEYWORD

본 프로젝트의 핵심은 알고리즘을 단순히 적용하는 것이 아니라, **따릉이 재배치 문제를 MDP로 정의하고 State와 Action을 문제 특성에 맞게 재구성한 뒤 여러 RL 알고리즘이 이 구조에서 어떻게 반응하는지 비교한 것이다.**

PROBLEM

왜 강화학습인가?

따릉이 재배치는 순차 의사결정 문제

01



확보한 데이터와 문제의 성격

정류소별 10분 대여/반납 이력, 위치
·Capacity, 날씨 데이터를 통해 **하루
Episode 시뮬레이션**이 가능합니다. 트
럭 이동 후 재고 상태 변화를 계산할 수
있어 시뮬레이터 기반 MDP 모델링에 최
적화된 환경입니다.

02



수요 예측을 통 한 최적화

전체 정류소를 직접 Action으로 두면 탐
색 공간이 너무 넓어 학습이 어렵습니다.
1시간 수요를 먼저 예측하여 "**불균형 임
계치**"를 넘는 정류장들만 **Top-K 후보**로
추출함으로써 Action Space를 효율적으
로 축소했습니다.

03



논문 및 이론적 근거

KDD 2018 Hourly rentals 예측이 재배치의
핵심 입력값임을 입증

Liang et al. (2024) Dynamic Rebalancing을
MDP로 공식화하여 접근

Sutton & Barto RL의 Trial-and-error와
Delayed Reward가 문제 해결의 핵심

PROJECT OBJECTIVES

프로젝트 목표 : Baseline 알고리즘을 뛰어넘는 RL 구현

Baseline: Most Imbalanced 정책

01

학습 안 함, 규칙 기반

매 Step 모든 정류소의 현재 재고와 목표 재고(Capacity 50%)의 차이를 분석

02

가장 불균형한 곳으로 이동 (Greedy)

- 트럭 공차: 잉여(Bikes - Target)가 가장 큰 곳에서 상차
- 트럭 만차: 부족(Target - Bikes)이 가장 큰 곳에 하차

GOAL STATUS

Delta > 0

Delta = Model reward - Baseline reward

re
ndi
ng
_u
p

주제 1. What to Set?

수요예측 feature 를 state 에 포함하면 에이전트가 미래 불균형을 미리 관측하여 선제적 재배치를 학습할 수 있을 것인가?

주제 2. How to Optimize?

Action space 를 점수 기반 12개 후보로 축소하면 탐색 효율 및 보상이 개선될까?

주제 3. How to Train?

복잡한 이산 행동 공간에서 On-policy(REINFORCE/A2C), DQN, PPO 등이 최적 학습하는 조건은 어떤 것일까?

ENVIRONMENT & DATASET

실험환경 및 데이터

3,341개

Bicycle Stations



25개

Districts



Dataset Split

✓ 시계열 분할 (Chronological Split)

섞지 않고 날짜 순으로 정렬하여 분할



* 랜덤 셔플 방식은 미래 패턴을 학습하는 데이터 Leakage가 발생할 수 있어 시계열 분할 방식으로 검증함

Environment

대상	서울시 전체 25개 구(마포·관악 등) 정류소 3,341개
에이전트	재배치 트럭 3대
에피소드 구성	144 steps (10분 단위, 24시간)
행동 공간	ex) 마포구 146개 → TOP K [3, 6, 9, 12] (Action Space 축소)
기준 모델(Baseline)	Most Imbalanced 규칙 기반 정책 (비교 대조군)

Dataset Inventory

데이터셋	출처	레코드 수	데이터 설명
stations.parquet	서울열린데이터광장	3,341	전체 정류소 마스터
trips.parquet	서울열린데이터광장	1,267,998	2025 대여/반납 이력
weather_10min.parquet	기상청	52,549	2025 기상 관측
demand_forecast_1h.parquet	HistGradientBoosting Regressor	6,413,662	RL Holdout 수요예측

MDP 설계 : State · Action · Reward

State

정류소 재고

현재 재고 비율 (bikes / capacity)

수요예측 ★

1시간 뒤 재고 부족/포화 가능성을 ML 모델로 수치화하여 에이전트에 전달 (pred_net_1h)


트럭 및 환경 정보

트럭 위치·적재·이동상태, 주말/공휴일, 날씨

```
pred_net_1h = returns -
rentals
projected_dev =
(bikes+net)/cap
```

Action

전체 3,341개 정류소 탐색의 비효율성을 개선하기 위해 정류소마다 Top-K 후보 구조 도입



```
Score = Forecast_Imbalance
- Distance_Penalty
- Zone_Penalty
```

Reward

보상은 덜 음수일수록 좋음

주요 변수

Stockout	-1.0	대여 실패
Full	-0.8	반납 실패
Travel km	-0.008	이동 거리
Travel Step	-0.002	이동 시간

```
r_t = -1.0×stockout -
0.8×full
- 0.008×km - 0.002×step
```

Reward 설계 예시: 실패와 불필요한 이동을 줄여 누적 보상을 높인다

01 Stockout Penalty

정류소에 자전거가 부족해 대여 수요를 처리하지 못하면 발생하는 **음수 보상**입니다. 출근 시간대와 같이 수요가 집중되는 정류소를 조기에 관리하지 못하면 다음 Step에서 대규모 Stockout이 발생합니다.

$$r_{\text{stockout}} = -1.0 \times \text{stockout}$$

lost rentals 및 unsatisfied demand를 최소화하는 것이 BSS 핵심 목표.

02 Full Penalty

정류소 거치대가 가득 차 반납 수요를 처리하지 못할 때 부여되는 **음수 보상**입니다. 반납이 집중되는 역세권 주변 공간을 선제적으로 비워두지 않을 경우 Full 상태 정류소가 증가합니다.

$$r_{\text{full}} = -0.8 \times \text{full}$$

full/empty 정류소 방치가 서비스 전체의 신뢰도를 저해하는 주요 원인.

03 Travel Cost

이동 거리가 늘어남에 따라 비용이 비례하여 증가합니다. 단순 불균형을 해결하기 위해 먼 정류소로 무리하게 이동하는 것을 막고, **이동 효율성을 고려한 최적 경로**를 유도합니다.

$$r_{\text{travel}} = -0.008 \times \text{km} - 0.002 \times \text{step}$$

논문 근거: vehicle-based rebalancing은 운영비와 routing cost를 동시에 극복해야 함.



핵심 문제해결 과제: 특정 Action의 결과가 즉각적인 Reward로 바로 이어지지 않기 때문에, 인과관계 파악이 정교해야 합니다. 본 과제의 Episode는 하루 24시간 동안의 시뮬레이션 단위(1Day Loop)로 정의됩니다.

ALGORITHM OVERVIEW

강화학습 알고리즘 개요

Classification Matrix

	Value-based	Policy / AC
On-policy	REINFORCE	A2C / PPO
Off-policy	Double DQN	—

REINFORCE : Policy Gradient

```
advantages = returns - value_net(states)
policy_loss = -(log_probs * advantages).mean()
```

PPO : Clipped Objective

```
ratio = exp(log_probs - old_log_probs)
surr2 = clamp(ratio, 1-e, 1+e) * advantages
loss = -min(surr1, surr2).mean()
```

※ A2C, PPO 는 Actor-Critic 구조를 사용함

핵심 아이디어

알고리즘	분류	핵심 아이디어
REINFORCE	On-policy / PG	에피소드 종료 후 Reward-to-go 로 Policy Gradient 직접 업데이트 (Monte Carlo)
A2C	On-policy / AC	Actor-Critic 분리, Advantage 추정으로 Gradient 분산 감소 및 학습 가속
Double DQN	Off-policy / Value	Experience Replay + Target/Online 분리. 거대 상태에서는 deadly triad 위험
PPO	On-policy / AC	old/new policy ratio 를 $[1-\epsilon, 1+\epsilon]$ 로 clipping 해 update 폭 제한 (clipped surrogate)
LinUCB	Contextual Bandit	즉시 Reward 집중 및 장기 누적 return 반영 불가

Experiment Result

실험 결과

EXPERIMENT DESIGN

하이퍼파라미터

2025년 데이터 시계열 분할 · 73일 holdout 평가 · 구별 MostImbalanced 대비 Delta 비교 (참고) Mostimbalanced : 가장 불균형한 정류소를 찾는 규칙 기반 휴리스틱

항목	REINFORCE	A2C	Double DQN	PPO
학습량 (Total)	500 episodes	500 episodes	200,000 steps	200,000 steps
할인율 γ / λ	0.99	0.99 / GAE 0.95	0.99	0.99 / GAE 0.95
Network Hidden	256, 256	256, 256	256, 256	pi / vf 256, 256
Policy LR	3e-4	1e-4	5e-4 (dqn_small)	1e-4
Value LR / coef	1e-3	3e-4	—	vf_coef 0.5
Batch · n_steps	episode	32	128 / train_freq 4	256 · n_steps 256
Replay / target	—	—	200k buffer · target 2k	—
후보 Action (Top-K)	3·6·9·12·15	3·6·9·12·15	12 (dqn) / 8·10·12·15 (small)	3·6·9·12·15
탐색 / 안정성	Advantage normalize	Advantage normalize	ϵ 1.0→0.05 (frac 0.3)	clip 0.1 · target_kl 0.03 · ent 3e-3

실험 목적: REINFORCE 및 A2C 비교

실험 목적

수요예측 feature 와 Top-K 후보
행동 구조를 적용한 재배치
환경에서, TD 기반 A2C가 MC 기반
REINFORCE 보다 더 안정적인지
검증합니다.

핵심 차이

REINFORCE : MC return - $V(s)$
에피소드 단위

A2C : $r + \gamma V(s') - V(s)$ 스텝 단위

알고리즘 원리 비교

①

REINFORCE는 에피소드 종료 후 MC return - $V(s)$ baseline으로 업데이트해 분산이 크고, A2C는 1-step TD advantage($r + \gamma V(s') - V(s)$)로 학습해 분산을 줄이게 되며 이런 차이가 학습의 결과로 이어지는지 비교합니다.

실험 설계

②

서울 25개 구 전체 Top-K(다음 방문 정류소)12 학습 → Best/Worst 구에서 Top-K-seed screening 선정 → 25개 구 재학습 결과를 73일 holdout 환경에서 비교합니다.

평가 기준

③

Delta = RL reward - MostImbalanced 휴리스틱 reward,
평균 Delta · 구별 승리 수 · seed 표준편차 · Best-Final gap을
함께 검증합니다.

참고) MostImbalanced 휴리스틱 : 가장 불균형한 정류소를 선택하는 규칙 기반


25구 전체 실험 결과: A2C가 Best 와 Final 모두에서 우위

핵심 결과

Top-K12 전체 실험에서 A2C는 평균 **Best Δ +13.0**, 25개 구 중 17승으로 baseline을 초과했습니다

REINFORCE는 **Best Δ 평균 -8.4**, 8승에 그쳤고, **Final Δ 평균은 -35.5**로 하락 폭이 더 컸습니다.

Δ = 모델 reward - MostImbalanced baseline reward (양수 = baseline 초과)



17 / 25

A2C Best 승리 구 수

8 / 25

REINFORCE Best 승리

+3.2

A2C Final Δ 평균

-35.5


REINFORCE Final Δ

EXPERIMENT 1 | REINFORCE VS A2C


학습 곡선: A2C는 더 빠르고 안정적으로 수렴

학습 진행에 따른 평가 성능 변화

A2C: 73일 평가 Delta 학습곡선



REINFORCE: 73일 평가 Delta 학습곡선



checkpoint별 73일 holdout 평균 Delta

지표	A2C	REINFORCE
Best episode 중앙값	100	300
100ep 이내 Best 도달 구 수	20 / 25	6 / 25
Best-Final gap 평균	12.0	24.3

해석

① 수렴 패턴

A2C는 약 100ep에서 0선(baseline)을 돌파해 +10 부근까지 상승, REINFORCE는 500ep까지 평균이 0선에 도달하지 못함 (최종 약 -24)

② 후반 상승/하락 거동

"A2C는 200ep 이후 완만한 plateau를 유지하되 말미에 소폭 하락 — 이것이 Best(중앙값 100ep)와 Final의 gap이 생기는 지점. REINFORCE는 350ep 부근 하락 후 400ep에 반등하는 진동 패턴으로, 후반까지 정책이 수렴하지 않음"


③ IQR(구별 편차) 추이

"A2C의 IQR 밴드는 학습이 진행되며 0 주변으로 좁아지는 반면, REINFORCE는 끝까지 -80~+10의 넓은 밴드를 유지 → 같은 설정에서도 구별 결과 편차가 해소되지 않음"

gap 최대 사례

REINFORCE 구로구 127.7
(Best +13.2 → Final -114.4)

Top-K Ablation – REINFORCE 는 후보 수(k)에 민감



관찰

- A2C는 K 변화에 완만하게 반응 (K=3~15 전 구간 양수 중앙값)
- REINFORCE는 K=9 이상에서 급락 — MC 분산이 커진 action space와 결합
- 구별 heatmap상 같은 K도 구마다 다르게 작동 → 단일 구 최고값이 아닌 중앙값·승리 수·seed 안정성으로 K 선정


* subset screening이므로 selection bias 가능성 있음

선정 여러 구의 중앙값과 안정성을 종합해 최종 full run은 Top-K9으로 진행

EXPERIMENT 1 | REINFORCE VS A2C

Seed 안정성 - 24배 차이 나는 분산

Seed 42/123/777 반복 실험: 구별 seed 표준편차



측정 방식 · 해석

- 같은 구 안에서 seed 3개(42/123/777)의 std를 먼저 구한 뒤 요약 → 구별 난이도와 seed 민감도를 분리
- A2C는 대부분 구가 0 근처에 모여 있고 일부 outlier만 평균을 끌어올림
- REINFORCE는 전반적으로 점이 위로 퍼져 seed에 민감

1.0

A2C Best std 중앙값

24.4

RF Best std 중앙값

10.2

A2C Best std 평균

28.3


RF Best std 평균

최대 outlier

REINFORCE 강서구 Final std 162.9
(seed 123에서 Final Δ -283.4)

최종 – Best Parameter로 전체 서울 학습

서울 25개 구 진단 지도: 성능, 수요 규모, 예측 난이도



해석: 성능 지도만 단독으로 보지 않고, 정류소/수요 규모와 예측 MAE를 함께 보면 구별 난이도와 학습 결과 차이를 설명하기 쉽다.

Figure. 서울 25개 구 진단 지도 — 구별 우수 알고리즘 Best Δ / 총 수요 규모 / 수요예측 MAE (보고서 Fig.3)

해석 성능 지도만 단독으로 보지 않고 수요 규모·예측 난이도(MAE)를 함께 보면, 어려운 구의 결과가 알고리즘 한계가 아닌 환경 난이도에서 비롯됨을 설명할 수 있습니다.

결론 : A2C + 수요예측 + Top-K 구조의 타당성

1

연구 질문에 대한 답

TD 기반 A2C는 MC 기반 REINFORCE보다 평균 성능(Best Δ +13.0 vs -8.4), 수렴 속도(Best ep 100 vs 300), seed 안정성(std 중앙값 1.0 vs 24.4) 모두에서 더 안정적이었습니다.

2

구조 선택의 근거

수요예측 feature는 미래 stockout/full 위험을 state에 반영하고, Top-K 후보는 action space를 줄여 학습을 가능하게 했습니다.

3

추가 검증과 한계

Bandit의 실패(0/10승)는 장기 가치 학습의 필요성을, VAE의 비개선은 critic이 이미 장기 가치를 학습하고 있음을 보여줍니다.

A2C도 일부 구(송파·강서)에선 후반 안정성이 저하될 수 있습니다.

최종 결론 A2C + 수요예측 state + Top-K 후보 action 조합이 본 담당 범위에서 가장 설득력 있는 모델입니다. REINFORCE는 policy gradient 구조를 설명하는 비교 모델로서 의미를 가지며, 그 한계가 곧 TD 방식의 가치를 입증합니다.

실험 목적 : 5개 실험으로 DQN 추월 조건 규명

실험 목적

가치 기반 DQN이
휴리스틱을 초과하는
환경 조건을 규명

핵심 검증

Delta > 0

Delta = DQN reward - 휴리스틱 reward
휴리스틱: MostImbalanced
(forecast 미사용 반응형 그리디, 결정적)

공통 보상 설계

stockout × (-1.0)
full × (-0.8)
이동km × (-0.008) step × (-0.002)

1

DQN FULL — 전체환경 25구

정류소 73~245개 + 트럭 3대에서 학습 가능한가? + 알고리즘 4종 비교

2

DQN SMALL — top-15 축소환경

환경을 "배울 수 있는 크기"로 줄이면 추월이 등장하는가?

3

시드별 민감도 — Best-3 vs Worst-3

추월·실패가 시드 운인지, 자치구 구조 때문인지 분리 검증

4

보상 분해 — 강남구가 휴리스틱을 추월하는 이유

Δ를 stockout / full / travel로 분해해 추월 메커니즘 규명

5

확장 레버 6종 — 추월 확대 시도

트럭↑·정류소↓·호라이즌·학습연장·PBRS·BC 워밍업의 효과 검증


환경 분석 : 전체환경 vs top-15 축소환경

실험 1	DQN FULL — 전체환경
정류소	73 ~ 245개 (자치구 전체)
트럭	3대
obs_dim	851 ~ 1,131
행동	candidate Top-K=12 후보 축소
학습	200K steps · chronological

실험 2~5	top-15 — dqn_small 축소환경
정류소	출퇴근 시간대의 불균형이 심한 상위 15개 정류소
트럭	1대 · 용량 20
obs_dim	92
평가	73일 holdout · paired (동일 실험 공유)
학습	200K steps · chronological

두 환경의 본질적 차이 — "상태·신용할당 공간의 크기"			
전체환경	top-15	가설	통제 변수
obs_dim 851~1,131 → 상태공간 폭발 + 지연 보상 신용할당 실패 + deadly triad 발생	obs_dim 92 → 학습 가능 크기 forecast 60차원이 미래 순수요 신호를 직접 전달	같은 DQN이라도 환경 크기에 따라 학습 성패가 갈린다 → 실험 1 vs 2로 검증	보상·분할(chronological)· 평가 지표(Δ) 동일 차이는 환경 규모뿐

실험 결과 ① : 전체환경 25구 — 학습 실패가 표준



1/25

추월 (서초 +26.0)

-234.1

최대 격차 (송파)

최하위

알고리즘 4종 중 DQN

알고리즘 비교 — A2C 1위, value-based DQN 최하위



※ 초기 7일 평균도 일관: 영등포 Δ-122.0 · 마포 미달 | DQN 부진 = deadly triad + 거대 상태·지연 보상 신용할당 + 강한 휴리스틱의 argmax 취약

실험 결과 ② : top-15 — 강남만 견고한 추월

+8.0

강남 3시드 평균 Δ (3/3 추월)


2/25

k15·seed42 추월 (보정평가 6/25)

$\pm 12\text{pt}$

송파 시드 변동폭 (부호 뒤집힘)

시드 민감도 — 견고한 추월은 강남 1구뿐 (3/3)



견고한 추월 = 강남 1구뿐

3시드 +6.0 ~ +10.9 일관 양수.
 송파는 시드운: 폭 12pt에 부호까지 뒤집힘 (s123에서 -3.7).

Worst-3는 구조적 실패

시드 노이즈($\pm 7 \sim 8\text{pt}$)가 격차(-18~-46)
 보다 작아 어떤 시드로도 구제 불가.
 → 추월은 시드가 아니라 자치구
 구조(수요 포화도)의 문제.

보상 분해 : 강남은 왜 이기나 — 가르는 변수는 "포화도"

보상 분해 — 강남 이득의 ~96%는 이동거리 절감 (-49.9km)



구	Δ	travel_kmΔ	미충족(휴)
강남 (비포화)	+11.0	-49.9	155
영등포 (포화)	-25.8	-2.2	534
강서 (포화)	-30.2	+1.7	773


강남 (비포화, 미충족 155건)

1트럭이 감당 가능 → 라우팅 슬랙 존재
 DQN이 forecast로 길목 선택
 → 이동 50km↓ + 미충족 12건↓
 → 이득의 ~96%가 미충족 감소


영등포·강서 (포화, 강남의 3.5~5배)

트럭 풀가동 → 줄일 슬랙 없음
 이동거리 휴리스틱과 동일(±2km)
 미충족에서 오히려 짐
 → 1트럭 물리천장 아래

하이퍼파라미터별 분석 : 확장 레버 6종 검증

정류소 수 스윙 — 강남만 단조 증가, $k \leq 10$ 추월 소멸

트럭 수 증가 — 전 자치구 악화 (휴리스틱이 2.4배 더 잘 활용)



호라이즌 h6→h12

악화

강남 +10.9→+8.4 · 영등포·강서 악화
h12는 예측오차 누적 노이즈

학습 연장 200k→400k

효과 없음

셋 다 100~260k 수렴 (강남 100k 평탄)
→ 200k 충분, 2배 연산 낭비

보상 셰이핑 PBRS

무효~악화

강남 무변화 · 강서 -30→-49 악화
PBRS는 최적정책 불변 → 수렴 구 무효

SLA BC 위밍업

추월 소멸

RL fine-tune이 BC를 한 번도 미초과
강남 +5.4 → -0.2 · 탐험 억제

🚩 4개 세션 · 6개 레버 전부 추월 확대 실패 — 한계는 DQN 하이퍼파라미터가 아니라 자치구 구조 (수요 포화도 · 1트럭 물리천장)

Replay Viewer

00:00 00:05:30

Pilotage

0.0 0.0

Baseline M2

0.0 0.0

Top 10

rank	station
0	1-1048

Performance: Delta +10.9

Double DQN 알고리즘 실험 종합 결론

"추월은 배울 수 있는 크기에서만 일어나며, 견고한 추월은 강남(비포화·단일트럭) 1곳뿐이다."

메커니즘 = forecast 기반 선제 라우팅 효율 (이동 -50km · 미충족 -12건) | 전체환경 알고리즘 1위는 A2C (17/25)

01

추월은 "배울 수 있는 크기"에서만 일어난다

전체환경(25구 중 1구, 단일일) = 학습 실패가 표준. obs_dim 851~1,131의 상태공간 폭발.
축소환경(top-15·1트럭, obs_dim 92)에서만 추월 등장.

02

실환경 견고 추월은 강남 1곳 — 조건은 구조

단일 트럭 · 비포화 자치구 · 충분한 정류소 수(k15)가 모두 갖춰져야 성립.
3시드 +6~+11 일관. 포화 구(강서·영등포)는 1트럭 물리전장으로 구조적 불가.

03

확장 레버 6종 전부 실패 — 한계는 문제 구조

트럭↑ / 정류소↓ / 호라이즌 / 학습연장 / PBRs / BC 워밍업 모두 무효~악화.
DQN 튜닝이 아니라 수요 포화 · 멀티트럭 협응 · 단순화 한계가 본질.

04

알고리즘 선택 : 전체환경에선 A2C가 1위, DQN 최하위

DQN 부진 = deadly triad + 거대 상태·자연 보상 신용할당 + 강한 휴리스틱의 argmax 취약.
확장하려면 튜닝보다 A2C/PPO 계열 전환이 효과적.

인사이트 도출

① "크기↔학습량" 균형이 RL 성패를 가른다

같은 DQN이 전체환경(실패) vs top-15(추월)로 갈린 건 알고리즘이 아니라 상태·신용할당 공간의 크기. 추월을 보려면 먼저 문제를 학습 가능한 규모로 정의해야 한다.

② forecast의 가치는 "비포화구"에서만 발현

forecast 선제 배치는 줄일 슬랙이 있을 때만 이득(강남). 포화구는 1트럭 물리천장이라 어떤 입력·튜닝도 천장을 못 뚫는다 → forecast/VAE/세이핑이 무효였던 이유.

③ value-based는 이 문제에 구조적으로 불리

거대 상태·지연 보상·강한 휴리스틱 조합에서 DQN은 최하위, on-policy 정책경사(A2C)가 17/25. 확장하려면 알고리즘을 A2C/PPO 계열로 바꾸는 게 튜닝보다 효과적.

④ 포화구 개선은 학습이 아니라 운영 변수

강서·영등포는 "트럭 수·용량"을 늘려 de-saturation 해야 RL이 의미를 갖는다. 1트럭 고정 하에 선 RL·휴리스틱 모두 천장 아래.

⑤ 운영 권고 : RL은 비포화·단일트럭 구에 선별 배치

포화·멀티트럭 구는 반응형 휴리스틱 유지. "대형구·멀티트럭에서 RL이 휴리스틱을 압도한다"는 주장은 데이터로 뒷받침되지 않는다.

⑥ 평가 방법론 교훈 : 검증 절차가 결론을 바꾼다

best-on-test 낙관 편향(강남 +10.9→+8.3 보정), split-mode 불일치 등 — 학습과 평가의 분할·체크포인트 정책을 일치시켜야 한다.

EXPERIMENT 3 | PPO

실험 목적 : Top-K 선정 및 Seed 재현성 검증

1



MaskablePPO + Top-K 구조 채택

sb3-contrib MaskablePPO로 action mask 적용, Top-K 후보 rank 선택 구조 설계

2



73일 chronological holdout 평가

앞 292일 학습, 뒤 73일 시계열 순 평가로 실제 환경 재현

3



Clipped update 안정성 효과 검증

clip_fraction ≈ 0 확인 $\rightarrow$ clipping 단독이 아닌 Top-K·lr 복합 효과 분석

4



Top-K 크기별 Best-Final gap 비교

K=3~15 ablation으로 gap 변화 측정, K=3에서 gap 5.5로 최소화

5



PPO diagnostics 지표 시계열 추적

approx_kl, clip_fraction, entropy_loss, explained_variance 시계열 모니터링

6




Seed 재현성 검증 (seed 42/123/777)


Top-K3 조건에서 6구 $\times$ 3 seed = 18 run, 전 run Best 양수 달성 확인

PPO 학습곡선

강복구 · QRDQN best3 권역



용산구 · QRDQN best3 권역



실험 결과

- 1



Top-K 크기별 성능: K=3이 최적
K3→Best/Final Δ 각 +35.1/+29.6,
Gap 5.5로 가장 안정적
- 2



K 증가 시 Best-Final Gap 급등
K12에서 Gap 26.2→55.4,
Final Δ -58.6으로 정책 망각 심화
- 3



시드 재현성: 18 run 전원 양수
Top-K3 기준 6구×3seed 모두 Best Δ 양수,
마포 std 0.7로 최고 안정
- 4



PPO 진단 지표: clipping 거의 미작동
clip_fraction≈0, approx_kl≈0 →
안정성운 Top-K 축소+보수적 lr 합작
- 5



Best vs Final 이중 평가 필수
Best만 보면 과대평가, Final 함께 확인 시 실
제 운용 성능 판별 가능
- 6



권고: K=3~6 + 보수적 하이퍼파라미터
target_kl_ 낮은 lr 병행 시 Gap 최소
화,
안정적 배포 가능 조건 확보

A

Top-K Ablation 결과 (Δ 성능 비교)

Top-K	Best Δ median	Final Δ median	Best-Final Gap
K3	+35.1	+29.6	5.5
K6	+25.0	+15.0	10.0
K9	+5.8	-0.4	6.2
K12	+1.5	-58.6	60.1
K15	-7.5	-28.5	21.0

B

시드별 Best Δ (Top-K3, 6구 × 3 seed = 18 run)

구	Seed-1	Seed-2	Seed-3	평균	표준편차
강남	+32.4	+35.5	+31.0	+32.9	2.3
종로	+28.7	+31.2	+27.9	+29.3	1.7
마포	+37.1	+36.4	+38.0	+37.2	0.7
성동	+26.6	+27.8	+25.9	+26.8	1.0
광진	+24.3	+27.1	+23.8	+25.1	1.7
동작	+29.6	+32.0	+28.2	+29.9	1.9
전체(18)	+29.8	+31.7	+29.1	+30.2	1.3




* Δ: Baseline 대비 성능 변화 (Reward 기준)


C

PPO 진단 지표 추이 (Top-K3 대표 run)


clip_fraction (평균)




approx_kl (평균)



entropy_loss (평균)



explained_variance (평균)



실험 목적 : 평가 신뢰성 검증

-  **두 가지 분할 방식의 핵심 차이** | Random Shuffle은 미래 데이터가 학습에 섞여 누수 발생
-  **시나리오 A: 무작위 셔플 설정** | 전체 데이터 무작위 분할 → 낙관적 편향으로 과대평가 위험
-  **시나리오 B: 시계열 분할 설정** | 앞 80%(292일) 학습, 뒤 20%(73일) 평가로 실제 배포 조건 반영
-  **평가 신뢰성 검증 목적** | 분할 방식이 모델 성능 수치를 얼마나 왜곡하는지 정량 비교
-  **현업 적용 가능성 판단 기준** | 시계열 분할만이 미래 일반화 능력을 측정하는 유효한 기준

데이터 분할 시나리오별 분석 결과

- 1

시나리오 A: 무작위 셔플 낙관적 편향

강남 +46.3, 강서 +45.6 등 대다수 양수 Δ → 데이터 누수로 과대평가
- 2

시나리오 B: 시계열 분할 현실 성능

전체 평균 Δ = -24.5, 10승 15패 → 실제 배포 조건 반영
- 3

최대 역전 사례: 강서구 비교

셔플 +55.6 → 시계열 -360.2 → 평가 방식이 결과를 결정
- 4

우세·열세 지역 분리 확인

노원 +54.6, 마포 +44.0 우세 / 영등포 -178.6, 송파 -114.3 열세
- 5

평가 신뢰성: 시계열 분할 필수

미래 일반화 능력 측정은 Chronological Split만이 유효한 기준



실험 목적: Seed 변화에 따른 성능 분석

1

Seed 의존성 검증 목적

PPO가 초기 난수에 얼마나 민감한지 정량 측정

2

Best 3 구 vs Worst 3 구 비교

학습 우수·저조 권역 각 3개 구 선정 대조 실험

3

18 run 실험 설계

seed {42, 123, 777} × 6개 구 = 총 18 run 동일 조건

4

재현성 및 수렴 안정성 측정

구별 3-seed 표준편차로 학습 재현성 정량 평가

5

포화 구조 문제 규명

추월 실패가 seed 문제인지 구조적 수요 포화인지 판별

하이퍼파라미터 고정 조건: lr=0.0001, clip_range=0.1, top-K=12 전 run 동일 적용

실험 결과

Best 3구: seed 안정성 최고 수준

- 노원·마포 std ≤ 1.2 , 3 seed 모두 휴리스틱 추월 재현

Worst 3구: seed 무관 추월 실패

- 강서·영등포, 모든 seed에서 추월 불가 → 수요 포화가 본질 원인

포화구 학습곡선: 초반 정체 패턴

- 강서·영등포는 20~60k 초반 best 후 학습 연장해도 개선 없음

알고리즘 문제 아닌 환경 구조 문제


- Worst 3 실패는 seed·하이퍼파라미터가 아닌 트럭 용량·수요 포화 병목

Best 3구 전체 통합 평가 확장 권장

- 재현성 확보된 노원·마포·구로는 25구 통합 실험으로 확장 적합

Worst 3구: 멀티에이전트·하이브리드 필요

- 단일 PPO 한계 명확 → Multi-agent 또는 휴리스틱 하이브리드 설계 권고



DISCUSSION

실험 결과에 대한 생각

Top-K 후보 도입 + Forecast feature 추가 — 이 두 설계 결정이 성능 향상의 핵심 동력
알고리즘 교체가 아닌 State · Action 구조 재설계로 전 알고리즘 Baseline(-448.3) 초과 달성

STEP 1

Top-K 도입 — 탐색 공간 문제 해결

146개 전체 정류소 탐색 → 점수 기반 상위 12개 후보로 축소. 이 전제 없이는 어떤 알고리즘도 안정적 학습 불가. K=3~12 Ablation에서 K 축소할수록 Best-Final Gap 감소 확인.

STEP 2

Forecast 추가 — 반응적 → 선제적 전략

현재 재고만 관측 → 1시간 후 예측 순수요(pred_net_1h) 포함. 미래 불균형 위험을 사전 감지해 선제적 재배치 학습 가능. 수요 예측 feature 포함 시 에이전트 조기 수렴 패턴 확인.

③ 두 설계의 상승 효과

Top-K로 탐색 효율을 확보하고 Forecast로 예측 기반 의사결정까지 더하자 모든 알고리즘이 Baseline을 유의미하게 넘어섰다. 결국 알고리즘 선택보다 올바른 문제 정의와 State · Action 설계가 선행되어야 함을 입증.

④ 알고리즘 차이는 설계 기반 위의 세부 조정

공통 기반(Top-K + Forecast)이 주어진 상황에서 알고리즘별 특성 차이가 드러남. A2C는 안정성(std 1.0), REINFORCE는 최대 Delta(+34.5) 우위. DQN · PPO의 한계도 설계 원칙 충족 후 명확히 진단 가능했다.

활용방안: 따릉이 확장성 및 실서비스 조건

01

따릉이 운영 보조

다음 1시간 수요를 반영해 어떤 정류소를 우선 방문할지 후보를 제안한다. 사람 운영자가 최종 판단하는 '재배치 우선순위 추천 도구'로 활용 가능. 현재는 simulator 기반 의사결정 보조 단계다.

02

공공데이터 확장 사례

공영주차장 혼잡 완화, 전기차 충전소 대기 관리, 공공자전거·킵보드 재배치, 버스·택시 수요 대응. 공통점: 수요가 시간에 따라 변하고, 현재 배치가 미래 비용을 바꾼다.

03

실서비스 전 조건

실시간 재고 API, 차량 수/기사 근무 시간, 도로 이동 시간, 안전/교통 규칙, 정책 설명 가능성(XAI) 등 현재 시뮬레이션 기반에서 위 조건들의 추가 검증이 필요하다.

활용 범위: 공유자원 배치 · 혼잡 완화 · 재고·인력 재배치 — ‘예측 후 순차적으로 움직여야 하는’ 공공서비스 문제 전반에 응용 가능

결론 및 참고문헌

1

순차 의사결정 문제 정의

따릉이 재배치는 정류소 재고와 미래 수요가 함께 변하는 순차 의사결정 문제다.

2

핵심 설계 및 문제 축소

ML 수요예측 State 제공 및 Top-K 행동 구조로 RL 탐색 크기 축소

3

알고리즘별 안정성 평가

Delta · Best-Final gap · seed std 복합 지표를 통한 안정성 분석

!

핵심 메시지

단순 알고리즘 실험을 넘어, RL용 MDP와 평가 프로토콜 구축이 핵심

▶ 참고문헌

- Liang et al. (2024) — BSS dynamic rebalancing MDP 정의 → 3p/6p 근거
- KDD 2018 demand prediction — hourly station-level rentals/returns → 5p/6p State 근거
- PPO bike rebalancing / data-driven rebalancing studies → 7p Hybrid 구조 근거
- Dulac-Arnold et al. (2015), Action Elimination (2018) → 4p/6p Top-K 근거
- Schulman et al. (2017) — PPO clipped surrogate objective → 8p/13p PPO 안정화 근거
- Henderson et al. (2018) — RL seed variance → 4p/10p seed 평가 근거
- Sutton & Barto (2018) — MDP, return, TD/MC 기본 개념 → 3p/8p 용어 근거

END OF DOCUMENT

감사합니다